

MACHINE LEARNING
ANALISIS & IMPLEMENTASI *DECISION TREE* & *NAIVE BAYES*



Disusun Oleh:

Nurmelizah – G1A024013

Dosen Pengampu:

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU
2026

BAGIAN A – ANALISIS KONSEP (INDIVIDU)

1. Jelaskan kapan *Decision Tree* lebih cocok digunakan dibanding *Naive Bayes* untuk kasus prediksi kelulusan ini. Beri 2 alasan!

Jawab:

Decision Tree dapat menjadi pilihan yang lebih sesuai untuk prediksi kelulusan karena mampu membaca pola antarvariabel dengan lebih fleksibel serta memberikan hasil yang mudah dijelaskan.

- a. Dapat mengolah hubungan antarfitur yang saling berkaitan. Dalam prediksi kelulusan, suatu faktor tidak selalu memberikan pengaruh yang sama pada semua mahasiswa. Misalnya, mahasiswa dengan jam belajar tinggi belum tentu memiliki peluang lulus tinggi apabila tingkat kehadirannya rendah. *Decision Tree* dapat membentuk percabangan berdasarkan kombinasi kondisi tersebut sehingga pola *if-then* antarfitur dapat terlihat dengan jelas.
 - b. Hasil prediksi lebih mudah diinterpretasikan. *Decision Tree* menghasilkan struktur berupa cabang dan keputusan yang dapat diamati secara langsung. Misalnya, model dapat menunjukkan bahwa mahasiswa dengan kehadiran di atas 75% dan IPK tertentu masuk ke kategori lulus. Hal ini memudahkan dosen atau pihak akademik memahami alasan di balik suatu prediksi dibandingkan hasil *Naive Bayes* yang berbentuk perhitungan probabilitas.
2. Asumsi “independen” di *Naive Bayes*. Sebutkan 2 pasang fitur di dataset yang kemungkinan melanggar asumsi ini dan jelaskan kenapa!

Jawab:

Naive Bayes menganggap bahwa setiap fitur tidak memiliki ketergantungan satu sama lain ketika dikaitkan dengan kelas target. Dalam data prediksi kelulusan, terdapat beberapa fitur yang kemungkinan memiliki hubungan.

- a. Pasangan IPK dan Status_Beasiswa. Status penerimaan beasiswa dapat berkaitan dengan pencapaian akademik mahasiswa. Beberapa program beasiswa menetapkan persyaratan berupa IPK minimum sehingga mahasiswa yang menerima beasiswa cenderung memiliki IPK yang memenuhi standar tertentu. Dengan demikian, kedua fitur tersebut tidak sepenuhnya berdiri sendiri.
- b. Pasangan Kehadiran dan Jam_Belajar. Kedua variabel tersebut sama-sama dapat menggambarkan tingkat keterlibatan mahasiswa dalam kegiatan akademik. Mahasiswa yang memiliki kebiasaan belajar yang baik dapat memiliki kecenderungan untuk lebih aktif mengikuti perkuliahan. Karena adanya kemungkinan hubungan tersebut, asumsi independensi *Naive Bayes* dapat terganggu dan informasi dari kedua fitur berpotensi dihitung seolah-olah benar-benar terpisah.

3. Apa risiko overfitting pada *Decision Tree* di dataset ini? Bagaimana cara mengatasinya?

Jawab:

Overfitting dapat terjadi ketika *Decision Tree* dibuat terlalu kompleks dan mengikuti pola yang sangat spesifik pada data training. Pada dataset yang hanya terdiri dari sekitar 500 data, pohon yang terlalu dalam dapat membuat banyak percabangan hingga mempelajari noise atau kesalahan yang terdapat pada data training. Akibatnya, model dapat memiliki hasil sangat baik pada data training tetapi kurang mampu memprediksi data baru.

Untuk mengatasinya, kompleksitas pohon perlu dikendalikan. Salah satu caranya adalah menggunakan pre-pruning, misalnya dengan menetapkan nilai `max_depth`, `min_samples_split`, atau `min_samples_leaf`. Selain itu, dapat dilakukan post-pruning dengan menghapus cabang yang kurang memberikan kontribusi terhadap prediksi. Alternatif lainnya adalah menggunakan Random Forest, yang menggabungkan beberapa *Decision Tree* sehingga risiko model terlalu bergantung pada pola tertentu dapat dikurangi.