

TUGAS INDIVIDU ANALISIS KONSEP

Mata Kuliah Machine Learning



Disusun Oleh:

Tasya Triani (G1A024019)

Dosen Pengampu:

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

Bagian A – Analisis Konsep Tugas Individu

1. Jelaskan kapan Decision Tree lebih cocok digunakan dibanding Naive Bayes untuk kasus prediksi kelulusan ini?

Decision Tree lebih cocok digunakan ketika data memiliki hubungan antarfitur yang cukup kompleks dan keputusan dapat dibuat berdasarkan beberapa kondisi. Pada kasus prediksi kelulusan mahasiswa, terdapat beberapa fitur seperti IPK, kehadiran, jam belajar, organisasi, penghasilan orang tua, jenis kelamin, dan status beasiswa. Fitur-fitur tersebut dapat memberikan pengaruh yang berbeda terhadap kelulusan. Decision Tree dapat membagi data berdasarkan kondisi tertentu, misalnya berdasarkan IPK atau tingkat kehadiran, sehingga pola keputusan lebih mudah dipahami.

Alasan kedua adalah Decision Tree tidak memiliki asumsi independensi antarfitur seperti Naive Bayes. Dalam dataset ini, beberapa fitur kemungkinan memiliki hubungan, contohnya IPK dengan kehadiran serta IPK dengan jam belajar. Mahasiswa dengan kehadiran yang tinggi atau waktu belajar yang lebih banyak dapat memiliki kemungkinan memperoleh IPK yang lebih baik. Karena itu, Decision Tree dapat digunakan untuk menangani hubungan antarfitur tersebut tanpa harus menganggap setiap fitur berdiri sendiri. Selain itu, hasil Decision Tree juga relatif mudah diinterpretasikan karena keputusan model dapat dilihat melalui struktur cabang pohonnya.

2. Asumsi "independen" di Naive Bayes. Sebutkan 2 pasang fitur di dataset yang kemungkinan melanggar asumsi ini dan jelaskan kenapa!

Naive Bayes menggunakan asumsi bahwa setiap fitur bersifat independen satu sama lain dalam memprediksi kelas. Artinya, keberadaan atau nilai suatu fitur dianggap tidak bergantung pada fitur lainnya. Dalam kondisi data nyata, asumsi ini belum tentu terpenuhi karena beberapa variabel dapat memiliki hubungan atau keterkaitan.

Pasangan pertama adalah IPK dan kehadiran. Kehadiran mahasiswa dapat berhubungan dengan pencapaian akademik karena mahasiswa yang lebih sering mengikuti perkuliahan memiliki lebih banyak kesempatan untuk memahami materi.

Pasangan kedua adalah IPK dan jam belajar. Jumlah waktu yang digunakan untuk belajar dapat memengaruhi pemahaman mahasiswa dan pada akhirnya dapat berkaitan dengan nilai atau IPK. Oleh karena itu, kedua pasangan fitur tersebut kemungkinan tidak sepenuhnya independen sehingga dapat melanggar asumsi yang digunakan oleh Naive Bayes.

3. Apa risiko overfitting pada Decision Tree di dataset ini? Bagaimana cara mengatasinya?

Risiko overfitting pada Decision Tree terjadi ketika model terlalu menyesuaikan diri dengan data training. Hal ini biasanya terjadi jika pohon keputusan dibuat terlalu kompleks, memiliki terlalu banyak cabang, atau kedalamannya terlalu tinggi. Model mungkin dapat memperoleh hasil yang sangat baik pada data training, tetapi ketika diberikan data mahasiswa yang baru, hasil prediksinya dapat menurun karena model lebih banyak mempelajari pola khusus atau noise pada data training daripada pola yang benar-benar umum.

Untuk mengatasinya, kompleksitas Decision Tree perlu dibatasi. Salah satu caranya adalah menggunakan parameter `max_depth` untuk membatasi kedalaman pohon. Selain itu, dapat digunakan `min_samples_split` dan `min_samples_leaf` agar pembagian cabang tidak dilakukan pada jumlah data yang terlalu sedikit. Metode pruning juga dapat digunakan untuk menghilangkan cabang yang kurang diperlukan. Setelah itu, model dapat dievaluasi menggunakan train-test split atau cross-validation sehingga dapat diketahui apakah model mampu melakukan generalisasi dengan baik terhadap data yang belum pernah digunakan sebelumnya.